

UNIVERZITET U BEOGRADU
ELEKTROTEHNIČKI FAKULTET



Detekcija falsifikata potpisa
SEMINARSKI RAD

Mentor:

Prof. Dr Ana Gavrovska

Kandidat:

Nemanja Vasić 2021/0401

Beograd, 2025.

SADRŽAJ

Sadržaj	Str.
1. Uvod	1
2. Detekcija i verifikacija potpisa	3
2.1. Retinex filter	4
2.2. Histograms segmentacija	5
2.3. Označavanje povezanih komponenti	5
2.3.1. Povezane komponente	5
2.3.2. CCL (Connected components labeling)	6
2.4. Određivanje kontura	7
2.4.1. Suzuki-Abe algoritam	7
2.5. CNN (Convolutional Neural Network)	7
2.6. Određivanje performansi modela	8
2.6.1. Confusion matrix	8
2.6.2. Accuracy	9
2.6.3. Precision/Recall	9
2.6.4. Cost-Sensitive Accuracy	9
2.6.5. Area under the ROC curve	9
3. Metode i materijali	11
3.1. Materijali	12
3.2. Predprocesiranje	13
3.3. Određivanje praga	14
3.4. Kreiranje segmenata pomoću CCL-a i njihovo filtriranje	16
3.5. Izdvajanje potpisa	17
3.6. CNN	18
4. Rezultati i diskusija	20
4.1. Eksperimentalni rezultati za epohu 10	21
4.2. Eksperimentalni rezultati za epohu 26	22
4.3. Diskusija	23
4.3.1. Prednosti i mane detekcije potpisa	23
4.3.2. Prednosti i mane modela za verifikaciju	24
5. Zaključak	25
Spisak Histograma	26
Spisak Figura	26
Spisak Tabela	26
Spisak Slika	27
Spisak korišćenih skraćenica	28
Literatura	29

1.Uvod

Potpis se može predstaviti kao slika koja prenosi određeni šablon piksela koji je karakterističan za tu osobu. Ostavljamo ga na dokumentima, računima, ugovorima kao potvrdu identiteta, pa je zahtev za automatsku verifikaciju potpisa velika.[1]

Provera verodostojnosti potpisa može da bude *online* ili *offline*. *Online* provera snima kako se potpisujemo, pa se koriste obeležja pri određivanju falsifikata koja nisu vezana za potpis. Ta obeležja su kojom rukom pišemo, kako držimo olovku u njoj, brzine kojim pišemo određena slova, početni i krajnji potez rukom. Ove karakteristike su specifične za svaku osobu pa se ne mogu tako lako prekopirati.[2] Kod *offline* detektovanja, koje koristimo u ovom projektu, mi radimo sa slikom potpisa koju smo uzeli i uskladištili. Kod ovakve verifikacije koristimo obeležja zasnovana na obliku, a to su Baseline Slant Angle, Aspect Ratio, Normalized Area, Center of Gravity, Number of Cross Points, Number of Edge Points, nagib linije koja spaja centre gravitacija dve polovine slike potpisa.

U poslednjih nekoliko godina, oblast *offline* prepoznavanja i verifikacije potpisa beleži postepen, ali ograničen razvoj kada je reč o primeni tehnika dubokog učenja. Iako je tematika od praktičnog značaja u kontekstu forenzike, bankarstva i autentifikacije, relativno mali broj autora je istraživao ovu domenu koristeći savremene metode mašinskog učenja.

Na primer, Shahane je predložio sistem koji uključuje uklanjanje šuma, ekstrakciju karakteristika i verifikaciju, uz dodatne OCR metode za analizu brojeva računa i iznosa na čekovima. Iako njihov pristup nudi praktične nadogradnje, korišćene ivice i pragovi nisu bili dovoljno robusni za različite stilove potpisa, što ograničava generalizaciju sistema.

Fahmy koristi diskretnu talasnu transformaciju (DWT) za izdvajanje karakteristika, zajedno sa neuronskom mrežom s propagacijom greške unazad za klasifikaciju. Iako je postignuta tačnost od 95% za prave potpise impresivna, eksperiment je izveden na veoma malom skupu podataka (samo pet osoba), što otvara mogućnost pretreniranja i loše generalizacije.

Dalje, Zhu predlažu napredan pristup zasnovan na superviziranom učenju i Linear Discriminant Analysis (LDA), kako bi se kombinovali komplementarni deskriptori oblika potpisa. Njihov sistem koristi strukturalnu analizu u više skala slike za preciznije izdvajanje potpisa iz dokumenata, ali zbog svoje kompleksnosti zahteva dodatnu računarsku snagu i optimizaciju.[1]

U ovom radu se koriste obeležja niskog nivoa kao što su granice, debljine i nagib linija konture. Dalja obeležja kombinuju naučene obrasce kako bi našli složene obrasce kao što su tekstura, geometrijske inkosistencije, fluidnost poteza. Fokus je na strukturalnim anomalijama koje se ne mogu lako videti golim okom ali se mogu primetiti analizom feature mapa konvolucionih slojeva.

Ovaj rad je organizovan u pet poglavlja. U uvodnom govorimo o značajnim radovima i tehnikama koji se bave ovom temom. U drugom poglavlju govorimo o osnovnim pojmovima koji su vezani za detekciju potpisa, kao i osnovama CNN. Treće poglavlje govori o prikupljanu podataka, metodama koje su korišćene u pred procesiranju i procesiranju slike, kao i o sastavu CNN. Četvrto poglavlje iznosi eksperimentalne rezultate kao i kvantitativnu analizu. Peto poglavlje se odnosi na zaključak i mogućnosti za budući rad.[2]

2. Detekcija i verifikacija potpisa

U ovom poglavlju će se razmatrati teorijsku osnovu metoda korišćenih u ovom radu. Fokusiraće se na ključne tehnike kao što su detekcija kontura pomoću Suzuki-Abe algoritma koji omogućava precizno izdvajanje regiona od interesa iz binarnih slika, kao i konvolucione neuronske mreže (CNN), koje se koriste za automatsko izdvajanje i analizu karakterističnih obeležja potpisa u cilju njihove verifikacije.

2.1. RETINEX FILTAR

Retinex teorija (naziv je nastao od spoja reči retina i cortex) je teorija bojene vizije koju je razvio Edwin Land kako bi objasnio kako ljudski vizuelni sistem percipira boje na konstantan način, uprkos promenama u osvetljenju.

Retinex filter je algoritam zasnovan na Landovoj teoriji koji simulira način na koji ljudski mozak procesira boje i svetlost (Land je dokazao da boja nije svojstvo svetlosti već da mozak kombinuje „*svetlosne mape*“ u konačnu percepciju boje). Koristi se u obradi slika kako bi se poboljšalo osvetljenje, povećao kontrast u tamnim regionima, smanjio uticaj nejednakog osvetljenja (senke, izvor svetlosti).

Postoji nekoliko tipova (Single-Scale Retinex, Multi-Scale Retinex, Color Retinex), ali osnovni principi su sledeći:

1. Razdvajanje osvetljenja i refleksije

Neka je slika I proizvod osvetljenja (L) i refleksije (R):

$$I(x, y) = L(x, y) \cdot R(x, y) \quad (2.1)$$

2. Prelazak u logaritamski domen

Ovim se dobija pojednostavljenje jer proizvod pretvaramo u zbir:

$$\log I = \log L + \log R \quad (2.2)$$

Pošto se osvetljenje sporo menja možemo ga aproksimirati *Gaussovom* zamućenjem slike $\log L \approx \log(\text{blur}(I))$, tako kad se zameni ovo u jednačini (2.2) dobija se:

$$\log R = \log I - \log L \quad (2.3)$$

3. Povratak u normalni dome

Vraćanje jednačine (2.3) iz logaritamskog domena, i nakon normalizacije se dobija izlazak iz našeg filtra. Dokazano je da *Multi-Scale Retinex* daje bolje rezultate, on koristi različite vrednosti za sigma *Gaussovog filtra* i kombinuje ih.

Retinex filter se koristi za poboljšanje medicinskih slika (MRI, rendgen), preprocesiranju slika u digitalnoj obradi (detekcija objekata pod lošim osvetljenjem), kao i u fotografiji kako bi

smanjili uticaj senki. Ali on takođe ima i svoja ograničenja. Može stvoriti halo efekte oko ivica (zbog *Gaussovog filtera*), kao i da pojačava šum u tamnim oblastima slike.[3]

2.2. HISTOGRAMSKA SEGMENTACIJA

Segmentacija slike je proces podele slike na logičke segmente. Cilj segmentacije je da se identifikuju regije koje imaju zajedničke karakteristike poput intenziteta, boje, teksture ili oblika. Jedan od osnovnih pristupa segmentaciji jeste metoda zasnovana na histogramu slike.

Kod histogram segmentacije koristi se prag (threshold) koji se određuje na osnovu raspodele intenziteta piksela u slici. Svaki piksel se upoređuje sa zadatim pragom: ako je njegova vrednost manja od praga, dobija novi intenzitet – najčešće 0; u suprotnom, dobija vrednost 1. Rezultat ovog procesa je binarna slika u kojoj su regije jasno odvojene na osnovu njihovih intenziteta.

Postoji više metoda za određivanje praga. Kod slika sa izraženom razlikom između objekta i pozadine, globalni prag može biti dovoljan. Najpoznatije metode za određivanje globalnog praga uključuju **Otsu metodu**, **Renyi entropiju**, i druge statističke pristupe. Međutim, kod kompleksnijih slika, gde se intenziteti znatno razlikuju u različitim delovima slike, globalni prag može dati loše rezultate. U tim slučajevima koristi se **adaptivna segmentacija**, gde se prag računa lokalno, za svaki deo slike posebno, uzimajući u obzir okolinu svakog piksela.[4]

2.3. OZNAČAVANJE POVEZANIH KOMPONENTI

2.3.1 Povezane komponente

Deo slike naziva se povezanim ako između tačaka X i Y postoje tačke $X_1, X_2, \dots, X_n = Y$, tako da je svaka tačka X_i sused X_{i-1} gde je $1 \leq i \leq n$.

<pre> 1 1 1 1 1 1 1 1 </pre>	<pre> 1 1 </pre>	<pre> 1 1 </pre>	<pre> 1 1 1 1 1 1 1 </pre>
(a)	(b)	(c)	(d)

Figura 2.3.1 Primer povezanosti komponenta

Na figuri (a) jedinice su spojene a praznine nisu, na (b) i jedinice i praznine su spojene. Na figuri (c) praznine su spojene ali jedinice nisu, a na figuri (d) i jedinice i praznine su spojene, iako je možda suprotno intuiciji smatra se da je region povezan ako ima susede bar sa neke od 8 strana uključujući i dijagonale.[5]

2.3.2. CCL (*Connected Component labeling*)

CCL je metoda u kojoj se jedinstvena oznaka (labela) dodeljuje svakom objektu (ili povezanim komponentama. Metoda je neizostvan deo većina procesa za određivanje karaktera na slici. U većini slučajeva je jedan od vremenski najzahtevnijih procesa. Razmatramo binarne 2D slike jer su one uglavnom izlazni produkt iz pred procesiranja. Binarna slika sadrži dve vrste piksela: piksele objekta i piksele pozadine. Kod CCL-a problem je da se svim pikselima dodeli odgovarajuća labela.

Postoji nekoliko načina da se pristupi označavanju postojećih komponenta. Najjednostavniji način je da se slika uzastopno skenira kako bi se odredile prikladne labele dok ne bude više promena pri iteraciji. Svaki put kad se piksel skenira njegovi susedi u maski se proveravaju da li imaju odgovarajuću oznaku za trenutni piksel. Ako u maski pretrage nema piksela koji pripada objektu, trenutni piksel dobija novu privremenu oznaku. Ali ako u maski postoje pikseli koji pripadaju objektu, privremene oznake tih susednih piksela se smatraju ekvivalentnim, bira se jedna od njih kao reprezentativna, trenutnom pikselu se dodeljuje ta oznaka. Uobičajena strategija za izbor reprezentativne oznake jeste da se koristi najmanja oznaka. Napredniji algoritmi za označavanje mogu koristiti posebne strukture podataka za čuvanje informacija o ekvivalentnosti ili drugačiju strategiju za izbor reprezentativne oznake među ekvivalentnima.

Algoritam za označavanje se deli u tri široke kategorije: **multi-pass**, **two-pass** i **one-pass** algoritam.

Multi-pass algoritam zahteva veći broj prelaza preko slike kako bi odredio sve labele. Ako slika ima x piksela zahteva $O(x)$ vremena. Zbog toga što broj prelaza preko slike je povezan sa sadržajem na slici multi-pass nije optimalan. Najpoznatiji multi-pass algoritam je Suzukijev.[6]

Second-pass algoritam funkcioniše u tri faze. U prvoj fazi (fazi skeniranja), slika se prolazi redom i pikselima objekta se dodeljuju privremene (provisional) oznake, pri čemu se beleže i informacije o njihovim međusobnim ekvivalentnostima. U drugoj fazi (analiza), ove privremene oznake se analiziraju kako bi se odredile grupe ekvivalentnih oznaka koje pripadaju istim komponentama. U poslednjoj fazi (faza označavanja), u drugom prolazu kroz sliku, svakom pikselu se dodeljuje konačna oznaka na osnovu rezultata analize. Jedan od najefikasnijih pristupa u ovoj grupi koristi **union-find** strukturu podataka za evidentiranje ekvivalentnosti, što omogućava algoritmima da dostignu optimalnu vremensku složenost $O(p)$, gde je p ukupan broj piksela. Reprezentativan primer ovakvog pristupa je algoritam **Scan plus Union-Find (SUF)**.

S druge strane, *one-pass algoritmi* pokušavaju da izvrše označavanje prolaskom kroz sliku samo jednom. Oni pronalaze piksel koji pripada objektu i zatim rekurzivno ili iterativno proširuju istu oznaku na sve povezane piksele. Iako su efikasni u teoriji, u praksi često imaju problem sa neregularnim pristupom memoriji, što može dovesti do smanjenja performansi. Zbog toga se moderni pristupi trude da optimizuju ovu nepravilnost. Jedan od najefikasnijih jednoprolaznih algoritama za 2D slike je **Contour Tracing (CT)** algoritam, koji obeležava povezane komponente prateći njihove ivice. Ovaj algoritam je posebno značajan jer važi za najefikasniji sekvencijalni (neparalelni) algoritam u savremenoj literaturi.[6]

2.4 ODREĐIVANJE KONTURA

Konture predstavljaju granicu između objekata i kao takve su jako važne pri procesiranju slika. Metode koje detektuju krive su brojne. Metoda *snakes* dvodimenzionalnom energijom optimizovane spline krive evoluiraju ka ivicama objekata. Kriva minimizuje energiju koja kombinuje: internu energiju i eksternu energiju. *Intelligent Scissors* ovaj metod daje korisniku da označi početne tačke objekta, posle čega sistem sam pronalazi najkraći put koji se zalepi uz deo slike sa snažnom ivicom. *Level Set* predstavlja napredan pristup evoluciji kontura sistemom parcijalnih diferencijalnih jednačina.[7]

U projektu je korišćen Suzuki-Abe metod, koji je jedan od prvih formalno opisanih metoda za detekciju kontura.

2.4.1. Suzuki-Abe algoritam

Algoritam prvo izdvaja topologijsku strukturu date binarne slike. On je nadogradnja algoritma za praćenje ivica (border following algorithm), jer razlikuje spoljašnje i unutrašnje ivice. Nadogradnja uključuje i postavljanje jedinstvenih oznaka na svaku ivicu, umesto da se koristi ista obeležja za sve ivice i dodavanje metode za određivanje "roditeljske" ivice trenutno praćene ivice. Pomoću ovog algoritma možemo izdvojiti odnos okruženosti među ivicama, što odgovara odnosu okruženosti među povezanim komponentama. Ako je binarna slika uskladištena u obliku ivica, a odnos okruženosti se izdvoji ovim algoritmom, moguće je izvršiti jednostavnu obradu slike bez potrebe za rekonstrukcijom originalne slike. Ova metoda tako predstavlja efikasan način za skladištenje binarnih slika.

2.5. CNN – Convolutional Neural Network

Konvolucione neuralne mreže je napravljen kako bi radili sa mrežastim strukturama kao ulaznim vrednostima (input). Najočigledniji primer ovakvog inputa je 2D slika, ali mreža može raditi i sa tekstom. Ova vrsta podataka, dvodimenzionalna slika, pokazuje prostornu zavisnost jer susedni pikseli često imaju isti intezitet zato što predstavljaju istu boju. Dodatna dimenzija predstavlja boje što stvara trodimenzionalni ulazni volumen, zbog toga karakteristike u konvolucijskoj neuronskoj mreži zavise od prostorne udaljenosti.

Važna karakteristika ovakvih mreža je operacija konvolucije. Ova operacija je korisna kada se obrađuju podaci koji imaju visoki nivo prostorne ili druge lokalne povezanosti. Konvolucione neuronske mreže koriste konvoluciju u bar jednom sloju.

Tajna uspeha bilo koje neuronske arhitekture leži u projektovanju strukture mreže uz semantičko razumevanje domene na koju se primenjuje. Konvolucione neuronske mreže zasnivaju se upravo na ovom principu, jer koriste retke veze uz visok stepen deljenja parametara na način osetljiv na domenu. Drugim rečima, nije svako stanje u određenom sloju povezano sa stanjima u prethodnom sloju na nasumičan način. Umesto toga, vrednost karakteristike u određenom sloju povezana je samo sa lokalnim prostornim područjem u prethodnom sloju, uz dosledan skup zajedničkih parametara koji se primenjuju na celu prostornu strukturu slike.[9]

2.6 ODREĐIVANJE PERFORMANSI MODELA

Kada imamo model koji je naš alogoritam za mašinsko učenje napravio koristeći set za treniranje kako da kažemo da je dobar. Koristimo metrike kako bismo odredili da li je model dobar. Za modele koji vrše klasifikaciju najkorišćenije metrike su:

- ***confusion matrix,***
- ***accuracy,***
- ***cost-sensitive accuracy,***
- ***precision/ recall, and***
- ***area under the ROC curve.***

2.6.1. Confusion matrix

The confusion matrix je tabela koja pokazuje kako je uspešan model klasifikacije u tačnom predviđanju primera koji pripadaju različitim klasama.

	original (predikcija)	fake (predikcija)
original (realnost)	TP	FN
fake (realnost)	FP	TN

Tabela 2.6. Confusion matrix

Tabela gore prikazuje confusion matrix. U slučaju da je predikcija tačna a i realnost tačna onda je to **true positive (TP)**, a ako je stvarnost netačna onda je **false positive (FP)**. Kada je predikcija netačna a stvarnost tačna onda je **false negative (FN)**, a ako je stvarnost netačna onda je **true negative(TN)**.

2.6.2. Accuracy

Tačnost je broj ukupno tačnih klasifikovanih primera podeljen sa ukupnim brojem klasifikovanih primera.

$$Accuracy = \frac{TP+TN}{TP+TN+FP+FN} \quad (1)$$

2.6.3. Precision/Recall

Dve najpopularnije metrike za modele su **preciznost** i **odziv**. **Preciznost** je odnos pozitivnih tačnih predikcija u odnosu na ukupan broj pozitivnih predikcija.

$$Precision = \frac{TP}{TP+FP} \quad (2)$$

Odziv je odnos tačnih pozitivnih predikcija sa ukupnim broj pozitivnih primera.

$$Recall = \frac{TP}{TP+FN} \quad (3)$$

2.6.4. Cost-Sensitive Accuracy

Kada imamo klasifikaciju više klasa, koje imaju različito važnost nama, možemo koristiti **cost-sensitive accuracy**. Mi dodeljuje vrednosti za FP i FN. I onda kada popunimo confusion matrix mi vrednosti koje smo dobili za FP i FN množimo sa vrednost koju smo stavili pre nego što iskoristimo jednačinu (1).

2.6.5. Area under the ROC curve

ROC kriva (Receiver Operating Characteristic) prikazuje odnos između **true positive rate (TPR)** i **false positive rate (FPR)** za različite pragove klasifikacije. TPR je definisan kao:

$$TP = \frac{TP}{TP+FN}, \quad FPR = \frac{FP}{FP+TN} \quad (3)$$

Koristi se za evaluaciju klasifikatora koji daju izlaz u vidu verovatnoće (npr. logistička regresija, neuronske mreže). ROC kriva se dobija tako što se prag klasifikacije menja u opsegu [0, 1], a za svaki prag izračunavaju se TPR i FPR. Na osnovu toga crta se ROC kriva, a **AUC (Area Under the Curve)** meri ukupnu uspešnost klasifikatora što je AUC veći, model je precizniji.[10]

3. Metode i materijali

Skup podatak korišćen u ovom projektu sastoji se od 100 slika potpisa, pri čemu je polovina originalih, dok je druga polovina falsifikovanih. Projekat je podeljen u dve celine: *detekciju* i *verifikaciju* potpisa.

Pre procesa detekcije, na ulaznu sliku primenjuje se *retinex filter* kako bi umanjio uticaj senki i neujednačenog osvetljenja. Potom se slika konvertuje u sivu (grayscale) sliku, što omogućava jednostavniju obradu.

Zatim se vrši segmentacija slike pomoću histograma, sa ciljem uklanjanja neželjenih oblasti koje sa velikom verovatnoćom ne sadrže potpis. Na dobijenu binarnu sliku primenjuje se tehnika *povezane komponente* (CCL), kako bi se dodatno izolovali segmenti koji mogu predstavljati potpis.

Dobijeni segmenti izdvajaju iz slike koristeći modul *Cropper*, potom se koristi *Judger* koji odlučuje na osnovu određenog kriterijuma da li je segment potpis ili ne.

S obzirom na to da potpisi u ovom skupu često sadrže i ime i prezime, sistem prepoznaje i izdvaja dve regije. Te regije se spajaju u jedan potpis, i u zavisnosti od faze projekta, šalju se kao primer u tening skup ili u test skup podataka.

3.1. MATERIJALI

Materijali za ovaj projekat prikupljeni su tokom perioda od sedam meseci, počevši od 12. decembra 2024. godine, zaključno sa 31. julom 2025. godine. U prikupljanju podataka je učestvovalo 13 volontere, od čega 8 muškog i 5 ženskog pola, starosne dobi u rasponu od 20 do 24 godine.

Ukupno je prikupljeno 30 fotografija ručno pisanih potpisa, 15 slika predstavlja prave potpise a ostalih 15 falsifikate. U radu su pravi potpisi označavani kao original a falsifikati kao fake. Za potrebe snimanja korišćeno je ukupno šest kamera. Pet različitih uređaja je korišćeno za slikanje 9 potpisa, dok je preostalih 21 slika zabeleženo jednom kamerom. Tri fotografije su napravljene kamerom visoke rezolucije od 50 megapiksela, dok su ostale snimane uređajima sa rezolucijom od 12 megapiksela i nižom.

Distibucija slika je sledeća: 24% slika je u visokoj rezoluciji od 3768×8160 ili 8160×3768 piksela, 46% u rezoluciji 4000×1848 ili obrnuto, dok je za preostalih 30% korišćena raznovrsna rezolucija





Figura 3.1. Raspodela rezolucija slika potpis

Većina slika (preko 70%) slikano je pod baldim uglom, kako bi se minimizovao uticaj senki. Potpisi su ispisani na belom papiru. U 21 slučaju korišćena je tehnička olovka sa minom poluprečnika 0.75mm, dok je za preostalih 9 korišćena hemijska olovka.

Senke su česta pojava na slikama. Na 6 slika senke prekrivaju više od 20% površine. Kod ostalih slika senke su slabog inteziteta ili potpuno izostaju. Dodatno 4 slike imaju plavičasto osvetljenje, što je uticalo na procesiranje tih slika.



Slika 3.1. Slika koja ima izraženu plavičastu pozadinu


3.2. PRED PROCESIRANJE

U okviru predprocesiranja, primenjuje se **Multi-Scale Retinex** (MSR) filter sa ciljem redukcije uticaja senki i neujednačenog osvetljenja koje može otežati detekciju potpisa. Ovaj filter omogućava očuvanje lokalnog kontrasta o poboljšanje kvaliteta slike, naročito u delovima sa jakim senkama. U implementaciji su korišćene tri vrednosti za Gaussovu standardnu devijaciju ($\sigma = 15, 80, 200$), čime se postiže balans između globalnog i lokalnog osvetljenja slike.

U ranijim verzijama projekta korišćene su i dodatne metode, kao što su ***gama korekcija*** i morfološka ***dilacija***, međutim ove metode su izbačene nakon eksperimentalne evaluacije.

Gama korekcija je uklonjena jer se pokazalo da MSR filter samostalno pruža bolje rezultate na slikama sa izraženim senkama, bez potrebe za dodatnim korekcijama.

Dilacija, iako doprinosi boljoj istaknutosti potpisa, istovremeno je dovođila do narušavanja morfoloških karakteristika linija potpisa, što negativno utiče na kasnije faze validacije i klasifikacije.




Slika 3.2.1. Potpis pre korišćenja dilacije Slika 3.2.2. Potpis posle korišćenja dilacije

3.3. ODREĐIVANJE PRAGA

Semgentacija slike pomoću histograma koristi se u cilju uklanjanja svih neželjenih šumova. Histogram slike predstavlja broj piksela raspoređenih po intezitetu, a u slučaju slike koje sadrže isključivo potpis, histogram pokazuje jedan izraženi vrh.

Kako bi se utvrdio prag za segmentaciju slika se najpre konvertuje u **HSV** prosto boja, pri čemu se za prag koristi value (sjajnost) komponenta, ostale komponente ton boje i čistoću ne koristimo za prag. Iako postoje automatske metode za određivanje praga, poput ***Otsu-ovog algoritma*** ili metode po ***Gonzalesu***, one se nisu pokazale dovoljno pouzdanim u ovom slučaju. Umesto toga korišćena je analiza histogramске reprezentacije slike, kojom se prag određuje eksperimentalno.

Nakon više pokupaja, utvršeno je da se najbolji rezultati dobijaju kada se donja granica praga postavi neposredno pre vrha histograma. U praksi, te vrednosti su se kretale u opsegu od 110 do 200. Kod slika gde je potpis napravljen tehničkom olovkom, donja granica praga najčešće je oko 180, dok kod hemijske olovke najčešća vrednost oko 140.



Histogram 2.3.1. Histogramska reprezentacija potpisa

Jedan od problema koji se javljao tokom primene ove metode jeste situacija kada su slova u potpisu razdvojena, što može dovesti do togada algoritam detektuje više potpisa umesto jednog. Na primer, ime i prezime mogu biti podeljeni u tri semgmenta - deo imena, ostatak imena i prezime. Rešenje ovog problema dobija se pomeranjem donje granice praga malo iza vrh histograma, čime se dobija da svi delovi potpisa ostanu povezani u jednu segmentiranu oblast.

Handwritten text: *Handwritten signature or note.*

Handwritten text: *Handwritten signature or note.*

Slika 3.3.1. Segmentacija kada je donja granica praga stavljena na (0,0,160)

Slika 3.3.2. Segmentacija kada je donja granica praga stavljena na (0,0,175)

U slučaju da se na slici nakon retinex filtera i dalje nalazi jaki uticaji senke može se promeniti gornja granica praga kako bi se uklonio uticaj senke. Gornja granica (value) se u tom slučaju postavlja na vrednosti između opsega [195, 220].

3.4 KREIRANJE SEGMENTATA POMOĆU CCL I NJIHOVO FILTRIRANJE

Nakon segmentacije slike pomoću histograma i dobijanje binarne maske, vrši se filtriranje segmenata pomoću metode povezanih komponenti (CCL). Dobijeni segmenti se zatim filtriraju prema svojoj veličini, sa ciljem da se eliminišu mali segmenti (koji verovatno ne predstavljaju potpis, već npr. senke, zgužvan papir).

Kako bi se definisale donja i gornja granica veličine segmenata, koristi se prosečna veličina regiona, koja se računa kao proizvod visine i širine svakog segmenta, zatim se uzima aritmetička sredina tih vrednosti. Donja granica se dobija po formuli:

$$Donja_granica = outlier_weight \times avg_segment_size + outlier_bias \quad (3.1)$$

Gde su u okviru projekta vrednosti parametra $outlier_weight = 1$ i $outlier_bias = 100$. Gornja granica se dobija kada se donja pomnoži sa $amplifier$ (u projektu za $amplifier$ je uzeta vrednost 25)

$$Gornja_granica = Donja_granica \times amplifier \quad (3.2)$$

Dodatno, kako bi osigurali da iz obrade budu isključeni svi izuzetno mali segmenti (čak iako bi zbog prosečne veličine prošli inicijalne filtre), uveden je parametar minimalne dozvoljene veličine segmenta, koji je u projektu postavljen na 1000 piksela.

Prosečna veličina segmenta značajno varira od uslova kao što su kvalitet kamere, visina sa koje se potpis fotografiše, kao i osvetljenje i senke. U okviru projekta, prosečna veličina segmenta se kretala od 1.355 piksela pa do čak 3.014.200 piksela.

Zbog raznolike veličine segmenata dolazilo je do nedostataka pri segmentaciji (nekad se ne bi se izdvojila sva slova ili bi se detektovao samo ime ili samo prezime) zbog toga je poželjno da pri segmentaciji se na osnovu prosečne veličine segmenta promeniti parametre. Ako su segmenti mali (npr. height =48 width = 64) stavljamo manje granice segmenata tako što ćemo promeniti parametre. Za outlier_wieght stavljamo da je 3 ili više kako bismo osigurali da segmentiše veće segmente kako bi uzeli i slova koja je pre izostavljao. Za outlier_bias se stavlja manja vrednost, u većini slučajeva je dovoljno staviti 10 ali mogu se staviti i druge vrednosti. Amplifier se može ostaviti na 25 ali ako su segmenti i suviše mali može se staviti na 15 kako ne bi pokupio šumove koji su ostali na slici. Minimalna dozvoljena veličina se smanjuje i dovoljno je staviti je na 50 kako bi izostavili jako mali segmenti koji predstavljaju šum.

Kod slika koje su imale plavičasto osvetljenje se pojavio jedan jako neobična stvar. Kod sve četiri slike se potpis nije podelio na ime i prezime nego se detektovao kao celina, što je jako čudna pojava jer ni u jednoj od 26 slika nije uspeo da se dođe do ovoga nego je moralo veštački da se spajaju ime i prezime. Posledica ovoga je da su ove četiri slike lošijeg kvaliteta u odnosu na ostale slike u materijalu.



Slika 3.4. Potpis koji se detektovao na plavičastoj pozadini

3.5. IZDVAJANJE POTPISA

Nakon što se segmentacija izvrši, svakom segmentu koji ima površinu veću od unapred definisane minimalne veličine (u okviru projekta postavljeno na 2000 piksela) dodeljuje se jedinstvena oznaka (labela). Svaki od segmenta se zatim analizira kako bi se utvrdilo da li predstavlja potencijalni potpis.

Kriterijumi za klasifikaciju segmenta kao potpis zasnivaju se na sledećim uslovima: odnosu širine i visine segmenta (aspect ratio) i odnosu crnih piksela u odnosu na ukupan broj piksela.

Po pravilu, potpisi su znatno širi nego što su visoki, pa se kao dozvoljen opseg odnosa stanica stavlja 1:4, ovim kriterijumom se eliminišu segmenti koji su previše kvadratni ili vertikalno izduženi, jer takni oblici najverovatnije ne predstavljaju potpis.

Pošto potpis predstavlja tamne linije na beloj pozadini, možemo dodatno filtrirati segmente na osnovu odnosa crnih piksela i ukupnog broja piksela. Definisani su pragovi tako da se odbacuju svi segmenti koji imaju manje od 10% i više od 90% crnih piksela u odnosu na ukupan broj piksela.

Nakon ovoga se dobijaju dve slike koje su potpisi jedna slika je ime a druga prezime. Kako bi se ovo popravilo mi spajamo dve slike u jednu tako da na kraju dobijamo jednu sliku koja predstavlja potpun potpis osobe. Stavlja se da je veličina potpisa 512×1124 piksela.



Slika 3.5.1. Potpis imena slika NV18



Slika 3.5.2. Potpis prezimena slika NV18

3.6 MODEL ZA ODREĐIVANJE AUTENTIČNOSTI POTPISA

Konvoluciona neuralna mreža koja se koristi u projektu ima jedan ulazni sloj, tri skrivena (hidden) i jedan output layer. Kod ulaznog i sakrivenih slojeva se koristila **RELU** funkcija aktivacija. Dok se kod klasifikatora se koristi **sigmoid** funkcija kako bi se klasifikovalo da li je potpis original ili fake.


Input layer je tenzor veličine $1124 \times 512 \times 1$, 1124×512 je veličina slike na ulazu a 1 je treća dimenzija slike jer je gray scale (da je slika RGB onda bi bilo $1124 \times 512 \times 3$). Slika se potom smanjuje i izvlače se karakteristike (feature) mape. U prvom (input) sloju ih je 8.

Feature maps from conv1



Slika 3.6.1. Prikaz feature mapa koje izvalči input layer

Drugi sloj prihvata duplo manju rezoluciju slike 562×256 . Iz nje izlaze 16 karakterističnih slika. Tako će isto uraditi i treći i četvrti sloj. Četvrti sloj će imati 64 feature mape rezolucija 32×70 . One potom se pretvaraju u niz i nad njima se vrši klasifikacija tako da se na kraju dobijaju vredosti između 0 i 1 koje se pomoću sigmoid funkcije stavlja na 0 ili 1.



Slika 3.6.2.Arhitektura CNN

4. Rezultati i diskusija

Pošto ima ukupno 30 primera u bazi koristilo se cross-validation kao metod evaluacije ovog modela. Koristio se 5-fold cross-validation. Podeljena je baza primera u 5 grupa, gde će 24 primera ići na treniranje a 6 na testiranje modela. Grupe su opisane po broju original i fake primera, raspodelu možete videti na tabeli (4.1).

Tabela 4.1 Opis data setova

	testSet1	testSet2	testSet3	testSet4	testSet5
original	3	4	4	2	2
fake	3	2	2	4	4

Postavljena su dva slučaja, jedan kada je epoha stavljena na 10 a drugi kada je onda stavljena na 26.

4.1. EKSPERIMENTALNI REZULTATI ZA EPOHU 10

Kad je korišćen testSet1 dobili smo confusion matrix (4.1.1)

Tabela 4.1.1. Confussion matrix testSet1(EPOCHS =10)

	original(model)	fake(model)
original (realnost)	3	0
fake (realnost)	3	0

Iz ove matrice se vidi da imamo vrednosti samo za $TN = 3$ i $FP = 3$. Korišćenjem formula iz poglavlja 2.6 može se odrediti $Accuracy = 50\%$, $Precision = 50\%$ i $Recall = 100\%$. Iz ovih vrednosti se vidi da model zna da je svaki original pravi ali stavlja i da je svaki fake primer pravi. Za testSet2 se dobija bolji rezultat, njegova confusion matrix je:

Tabela 4.1.2. Confussion matrix testSet2(EPOCHS =10)

	original(model)	fake(model)
original (realnost)	4	0
fake (realnost)	1	1

$Accuracy$ ovog modela je $83,333\%$, $Precision$ je 80% , a $Recall$ je 100% . Iz ovoga se vidi da pri svakom njegovom pozitivnom predviđanju 20% su lažni pozitivni.

Za testSet3 se dobija 100% $Accuracy$, što se pridodaje činjenici da model ima samo dva fake primera i da je jedan od njih "lošiji" pokušaj plagijata.



Slika 4.1.1. "Lošiji" plagijat potpisa testSet3

TestSet4 dobija 50% Accuracy, Precision je svega 40% i Recall je 100%.

Tabela 4.1.3. Confussion matrix testSet4(EPOCHS =10)

	original(model)	fake(model)
original (realnost)	2	0
fake (realnost)	3	1

Iz testSet5 dobijamo najlošije rezultate do sada Accuracy je 33%, Precision je takođe 33% a Recall je 100%.

Tabela 4.1.4. Confussion matrix testSet5(EPOCHS =10)

	original(model)	fake(model)
original (realnost)	2	0
fake (realnost)	3	1

Sada kada uzmemo aritmetičku sredinu ovih rezultata dobijamo da je Accuracy = 56.667%, Precision = 53.57% i Recall = 100%. Iz ovih rezultata se vidi da model greši pri odlučivanju nad falsifikatom.

4.2. EKSPERIMENTALNI REZULTATI ZA EPOHU 26

Za testSet1 pri epohi 26 dobijaju je logično bolji rezultati nego kad je bilo epoha bila 10.

12

	original(model)	fake(model)
original (realnost)	3	0
fake (realnost)	0	3

Vidimo da je model tačno utvrdio da ima tri “original” i tri “fake” primera. Što znači da je accuracy, precision i recall 100%.

TestSet2 i testSet3 nam daje iste rezultate kao i testSet1 tačno predviđa falsifikate i originalne potpise.

TestSet4 i testSet5 nam daju lošije rezultate, Accuracy je 66.67%, Precision je 50% i Recall je 100%.

Tabela 4.2.2. Confussion matrix za testSet4 i testSet5(EPOCHS =26)

	original(model)	fake(model)
original (realnost)	2	0
fake (realnost)	2	2

Iz rezultata ovih setova vidimo da su oni mnogo bolji u odnosu na slučaj gde je epoha bila 10. Za vrednost Accuracy dobijamo 86.67% iz ovoga se vidi da je od 30 primera svega četiri loše klasifikovano. Za vrednost Precision-a dobijamo 78% što znači da ta četiri primera koja su loše klasifikovana su klasifikovana kao pogodci, “original” i za recall dobijamo 100%. Ovo znači da ako bude bilo greške ona će biti da je “fake” primere klasifikovan kao “original”.

4.3 DISKUSIJA

4.3.1. Mane i prednosti detekcije potpisa

Vreme za detekciju potpisa nije velika. Kod primera gde je slika veličine 8160x3768 piksela bilo je potrebno 5 minuta i 26 sekundi, dok je na slici veličine 3768x8160 bilo potrebno svega 34 sekunde. Mogu se na ulaz dovesti različite rezolucije i uz promenu parametara će se uspešno detektovati potpis, najmanja rezolucija slike je 715x289 kod PNV10 a najveće su bile 8160x3768 kod NV6. Ako dođe do deformacije na papiru neće značiti da mora da se odbaci primer. Senke nemaju veliki uticaj pri detekciji potpisa čak mogu pomoći pri detekciji. Zbog senki će postojati crni pikseli koji se nalaze po celoj površini i postoji šansa da će se neki od tih crnih piksela zapasti kod potpisa, između slova. Tako će tokom Suzuki-Abe algoritma oni pomoći detekciji potpisa.


Ovaj sistem ima i svoje mane. Prva mana je što za većinu slika moraju ručno da se nameštaju parametri, zbog različitih obeležja koje je karakterišu: osenčenost, čime je pisano,

osvetljenje, nagib kamere, udaljenost kamere od papira. Nemože da detektuje potpis kod svih primera. Negde su slova potpisa suviše udaljena jedna od druge pa se neđe detektovati. Tako su se dobili mnogi fragmenti potpisa.



Slika 4.3.1. Fragment pri detektovanju potpisa

Postoje primeri gde su ime i prezime suviše udaljeni jedno od drugoga pa algoritam ne može da detektuje i jedno i drugo u jednom pokušaju. Zbog toga se mora pokušati da se odvojeno detektuju ime i prezime, ali ni ovo nekada nema uspeha jer može doći do nepotpunog detektovanje dela potpisa. U nekim primerima se segmentacijom praga dovodi do morfološke deformacije potpisa, kroz izostavljanje piksela koji čine potpis.



Slika 4.3.2. Potpis levo je output algoritma, desno je input algoritma

Na slici 4.3.2. se vidi da postoji deformacija potpisa kod slova "H" kao i da poslednjim slovima nedostaju delovi. Nekada dolazi do podebljanja potpisa što izaziva veliki problem jer se time gube informacije iz njega.

4.3.2. Mane i prednosti CNN modela

Najveće mana ove konvolucione mreže je činjenica da ima malo training i test primera. Kod modela kod kog je korišćeno 10 epoha ostvarena je tačnost od svega 56%. Samo jedan tip greške se pojavljivao, a to je da ima mnogo veću šansu da kaže da je primer "original" nego "fake". U modelu iako je stavljeno 15 falsifikata on je detektovao u svih 5 setova samo dva dok je za ostalih 13 rekao da su "original". Dakle ovaj model naginje na tome da daje lažne pozitivne pogotke što nije dobro i čini njegu upotrebnu vrednost jakom malom, jer zašta će nam model koji za sve primere kaže da je pogodak. Povećanjem broja epoha se popravља situacija i sistem

postaje bolji. Dolazimo do tačnosti od 86.67%, ali i dalje se prave lažni pogodci (njih četiri). Setovi koji su imali najmanju tačnost su bili testSet4 i testSet5 koji su oboje imali po četiri falsifikata od kojih su samo dva dobro klasifikovana. Sa daljim povećanjem epoha dolazimo do daljeg pogoljšanja modela. Novom modelu je napravljenom pri testSet4-u je stavljeno 200 epoha i dobijena je tačnost od 83.33%, samo jedan primer je loše klasifikovan. Ovim se vidi da povećanjem epoha dolazimo da veće tačnosti, ali takođe i do sporijeg izvršenja. Kako bi sada se porpavili rezultati ovog modela mora ili da se doda još training i test primera ili da se smanji broj featura slojeva.

5. Zaključak

U ovom radu razvijem je sistem za detekciju i verifikaciju potpisa korišćenjem metoda obrade slike i konvolucionih neuronskih mreža (CNN). Sistem uspešno identifikuje potpisane regione koristeći kombinaciju ekstrakcije kontura, segmentacijom pomoću histograma i praga. Na izdvojene regione primenjuje se CNN model koji klasifikuje potpis kao „original“ ili „fake“. Postignuti rezultati prikazuju da je pristup efikasan u kontrolisanim uslovima.

Neki budući radovi koji bi mogli da nastanu iz ovog rada su: modifikacija same konvolucione mreže, smanjenjem featura slojeva ili prikupljanjem više primera, kako bi se napravio model veće efikasnosti i upotrebne vrednost, omogućavanje primene ovog sistema na pametnim urađajima (na pametnim telefonima ili tabletima), promena samog procesiranja slike kako bi se lakše dolazilo do samih primera.

HISTOGRAMI

Sadržaj	Str.
Histogram 2.3.1. Histogramska reprezentacija potpisa	15

FIGURE

Sadržaj	Str.
Figura 2.3.1. Primer povezanosti komponenata	5
Figura 3.1. Raspodela rezolucije slika potpisa	12

TABELE

Sadržaj	Str.
Tabela 2.6. Confussion matrix	18
Tabela 4.1. Opis data setova	21
Tabela 4.1.1. Confussion matrix testSet1 (Epochs = 10)	21
Tabela 4.1.2. Confussion matrix testSet2 (Epochs = 10)	21
Tabela 4.1.3. Confussion matrix testSet4 (Epochs = 10)	22
Tabela 4.1.4. Confussion matrix testSet5 (Epochs = 10)	22
Tabela 4.2.1. Confussion matrix testSet1 (Epochs = 26)	22
Tabela 4.2.2. Confussion matrix za testSet4 i testSet5 (Epochs = 26)	23

SPISAK SLIKA

Br.		Str.
Slika 3.1.	Potpis koji ima izraženu plavičastu pozadinu	13
Slika 3.2.1.	Potpis pre korišćenja dilacije	14
Slika 3.2.2.	Potpis posle korišćenja dilacije	14
Slika 3.3.1.	Segmentacija kada je donja granica praga stavljena na (0,0,160)	15
Slika 3.3.2.	Segmentacija kada je donja granica praga stavljena na (0,0,175)	15
Slika 3.4.	Potpis koji se detektovao na plavičastoj pozadin	17
Slika 3.5.1.	Potpis imena slika NV18	18
Slika 3.5.2.	Potpis prezimena slika NV18	18
Slika 3.6.1.	Prikaz feature mapa koje izvalči input layer	19
Slika 3.6.2.	Arhitektura CNN	19
Slika 4.1.1.	“Lošiji” plagijat potpisa testSet3	21
Slika 4.3.1.	Fragment pro detektovanju potpisa	24
Slika 4.3.2.	Potpis levo je output algoritma, desno je input	24

SPISAK KORIŠĆENIH SKRAĆENICA

Skraćenica	Pun naziv	Objašnjenje (na srpskom)
CNN	Convolution Neural Network	Konvolucione neuronske mreže
CCL	Connected Components Labeling	Obeležavanje povezanih komponenti
DWT	Discrete Wavelet Transform	Diskretna talasna transformacija
LDA	Linear Discriminant Analysis	Linearna diskriminaciona analiza
MRI	Magnetic Resonance Imaging	Magnetna rezonantna tomografija
MSR	Multi-Scale Retinex	Multi-skala Retineks filter
HSV	Hue, Saturation, Value	Nijansa, Zasićenost, Vrednost (boja)
TP	True Positive	Tačno pozitivni (slučajevi)
FP	False Positive	Lažno pozitivni (slučajevi)
TN	True Negative	Tačno negativni (slučajevi)
FN	False Negative	Lažno negativni (slučajevi)
ROC	Receiver Operating Characteristic	Karakteristika rada prijemnika
AUC	Area Under the Curve	Površina ispod krive
OCR	Optical Character Recognition	Optičko prepoznavanje karaktera
SUF	Scan plus Union-Find	Skeniranje sa Union-Find algoritmom
CT	Contour Tracing	Praćenje kontura
TPR	True Positive Rate	Stopa tačno pozitivnih
FPR	False Positive Rate	Stopa lažno pozitivnih
RELU	Rectified Linear Unit	Ispravljena linearna jedinica

LITERARURA:

- [1] T. A. Farag and A. A. El-Sayed, "Offline signature recognition using convolutional neural network," **Procedia Computer Science**, vol. 170, pp. 398–403, 2020. [Online]. <https://doi.org/10.1016/j.procs.2020.03.091>
- [2] A. Dhawan and A. R. Ganesan, "*Handwritten signature verification*," ECE 533 Project Report, Univ. of Wisconsin-Madison, 2012. pp. 3-5
- [3] E. H. Land, "The Retinex theory of color vision," *Scientific American*, vol. 237, no. 6, pp. 108–128, Dec. 1977.
- [4] Ravishankar Chityala, Sridevi Pudipeddo, Image Processing and Acquisition using Python 2014, pp. 139-149
- [5] F. Chang, C. J. Chen, and C. J. Lu, "A linear-time component-labeling algorithm using contour tracing technique," *Computer Vision and Image Understanding*, vol. 93, no. 2, pp. 206–220, 2004
- [6] Kenji Suzuki, Isao Horiba, and Noboru Sugie. Linear-time connected-component labeling based on sequential local operations. *Comput. Vis. Image Underst.*, 89(1):1–23, 2003.
- [7] R. Szeliski, "*Computer Vision: Algorithms and Applications*", Springer, 2010. pp. 235-243
- [8] T. Suzuki and F. Abe, "*Topological structural analysis of digitized binary images by border following*," *Computer Vision, Graphics, and Image Processing*, vol. 30, no. 1, pp. 32–46, 1985.
- [9] M. A. Nielsen, *Neural Networks and Deep Learning*, 2015. pp. 305-322
- [10] A. Burkov, *The Hundred-Page Machine Learning Book*, 1st ed. Andriy Burkov, 2019. pp. 65-68